Universidad Tecnológica de Tula-Tepeji

Ingeniería en Desarrollo de Software

Proyecto:

Análisis de comportamiento de compradores en comercio electrónico

Alumno:

Byron Chavez Molina

Docente :

Jose Luis Herrera Gallardo

Fecha:

13 de noviembre de 2026

1. Introducción

En esta actividad se realiza una exploración del conjunto de datos Online Shoppers Purchasing Intention Dataset, que contiene información sobre las visitas de usuarios a un sitio de comercio electrónico. El propósito es conocer cómo están organizados los datos, identificar sus variables y revisar si existen problemas como valores faltantes, registros duplicados o datos fuera de lo normal. También se realizan análisis estadísticos y visualizaciones para comprender mejor la información antes de comenzar con la limpieza y transformación de los datos.

2. Identificación y descripción del conjunto de datos

El conjunto de datos contiene 12,330 registros y 18 variables. Cada fila representa una sesión de navegación y cada columna almacena una característica de esa sesión. La información incluye páginas visitadas, tiempo de navegación, características técnicas del visitante y si la sesión terminó en una compra.

La fuente es UCI Machine Learning Repository. Se trata de datos generados por la actividad de los usuarios dentro de un sitio web de comercio electrónico. Por su organización en filas y columnas, es un conjunto de datos estructurado.

3. Diccionario de datos

La siguiente tabla resume el significado de las variables, su tipo y una posible utilidad dentro del análisis.

Variable	Descripción	Tipo Python	Tipo / clasificación	Unidad o categoría
Administrative	Páginas administrativas visitadas	int64	Cuantitativa discreta	Número de páginas
Administrative_Duration	Tiempo en páginas administrativas	float64	Cuantitativa continua	Segundos
Informational	Páginas informativas visitadas	int64	Cuantitativa discreta	Número de páginas
Informational_Duration	Tiempo en páginas informativas	float64	Cuantitativa continua	Segundos
ProductRelated	Páginas relacionadas con productos visitadas	int64	Cuantitativa discreta	Número de páginas
ProductRelated_Duration	Tiempo en páginas de productos	float64	Cuantitativa continua	Segundos
BounceRates	Tasa relacionada con sesiones de rebote	float64	Cuantitativa continua	Proporción
ExitRates	Tasa relacionada con salidas de páginas	float64	Cuantitativa continua	Proporción
PageValues	Valor asociado a las páginas visitadas	float64	Cuantitativa continua	Valor numérico
SpecialDay	Cercanía a fechas especiales	float64	Escala numérica	Escala de al
Month	Mes de la visita	str	Cualitativa nominal	Mes

OperatingSystems	Código del sistema operativo	int64	Cualitativa nominal	Código
Browser	Código del navegador	int64	Cualitativa nominal	Código
Region	Código de región	int64	Cualitativa nominal	Código
TrafficType	Código del tipo de tráfico	int64	Cualitativa nominal	Código
VisitorType	Tipo de visitante	str	Cualitativa nominal	Categoría
Weekend	Visita en fin de semana	bool	Cualitativa binaria	True/False
Revenue	La sesión terminó en compra	bool	Cualitativa binaria	True/False

Interpretación

El conjunto contiene variables numéricas y categóricas. Las variables de cantidad y duración permiten estudiar la navegación, mientras que las variables como navegador, sistema operativo, región y tipo de visitante describen características de las sesiones. Aunque OperatingSystems, Browser, Region y TrafficType se almacenan como números, representan códigos de categorías y por eso se consideran cualitativas nominales. La variable Revenue es especialmente importante porque indica si una sesión terminó en una compra.

4. Diagnóstico de calidad de los datos

4.1 Valores faltantes

La revisión mostró que las 18 variables tienen cero valores faltantes, equivalente al 0% en cada columna. Por lo tanto, no se identificaron datos vacíos en esta revisión.

4.2 Registros duplicados

Se encontraron 125 registros duplicados. Esto puede ocurrir cuando distintas sesiones presentan exactamente los mismos valores en todas las columnas. Los registros se conservaron durante esta actividad, ya que el objetivo es diagnosticar y no realizar todavía la limpieza.

4.3 Posibles inconsistencias

La variable Month contiene 10 categorías. Se observó una diferencia de formato entre el valor June y los meses abreviados como Jul. No necesariamente es un error, pero convendría unificar la escritura durante una etapa posterior. También se comprobó que las variables Revenue y Weekend utilizan valores booleanos True y False.

4.4 Revisión de valores negativos

En las variables revisadas relacionadas con cantidades de páginas, duración y tasas no se encontraron valores negativos. Esto evita detectar cantidades menores que cero en esas columnas, aunque no descarta otros tipos de inconsistencias.

Resumen del diagnóstico

Revisión	Resultado	Interpretación
Valores faltantes	0 en las 18 variables (0%)	No se identificaron datos vacíos.
Duplicados	125 filas	Se conservaron para no alterar los datos originales.
Valores negativos	0 en las variables revisadas	No se encontraron valores menores que cero.
Formato de Month	10 categorías; aparece June y Jul	Conviene revisar la uniformidad de las categorías.

5. Análisis estadístico

Se seleccionaron tres variables numéricas para calcular la media, mediana, mínimo, máximo y desviación estándar. Los resultados se muestran a continuación.

Estadístico	Administrative	ProductRelated	ProductRelated_Duration
Media	2.32	31.73	1194.75
Mediana	1.00	18.00	598.94
Mínimo	0.00	0.00	0.00
Máximo	27.00	705.00	63973.52

Desviación estándar	3.32	44.48	1913.67

Interpretación

Administrative tiene un promedio de 2.32 páginas y una mediana de 1, lo que indica que normalmente se visitan pocas páginas administrativas. ProductRelated tiene una media de 31.73 y una mediana de 18, por lo que algunas sesiones incluyen una cantidad mayor de páginas de productos. En ProductRelated_Duration, la media es de 1194.75 segundos y la mediana de 598.94 segundos. La diferencia entre ambos valores indica que algunas sesiones tuvieron tiempos de navegación mucho más largos que la mayoría.

6. Análisis de valores atípicos

Para identificar valores atípicos se utilizó el rango intercuartílico (IQR). Este método considera atípicos los valores que quedan por debajo de Q1 - 1.5 × IQR o por encima de Q3 + 1.5 × IQR.

Los resultados obtenidos fueron:

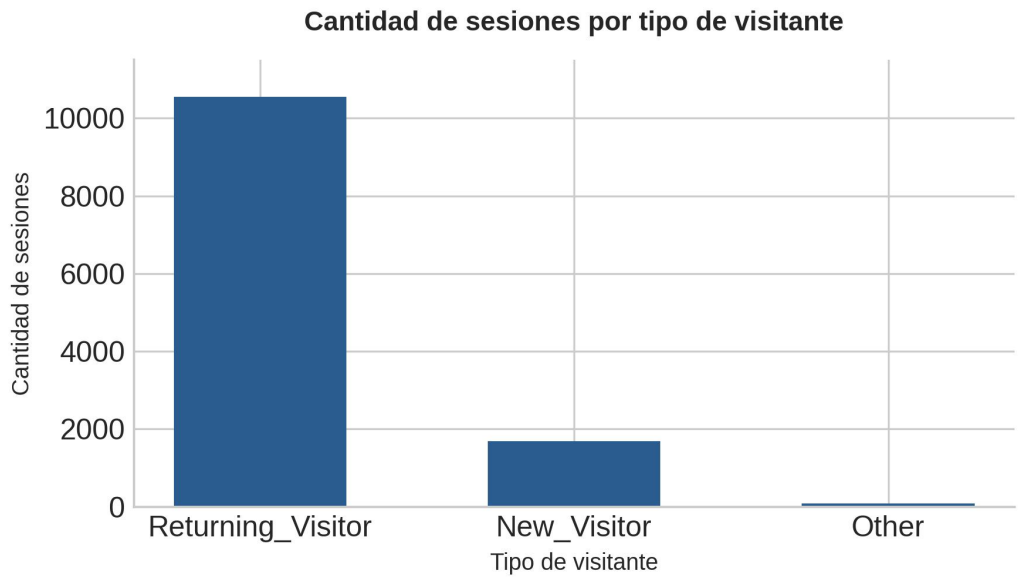
Variable	Límite inferior	Límite superior	Cantidad de valores atípicos
Administrative	-4.60	8.60	782
ProductRelated	-28.65	73.65	1,240
ProductRelated_Duration	-1,287.89	2,936.18	1,203

Los valores atípicos no necesariamente son errores. Pueden representar sesiones en las que los usuarios visitaron muchas páginas o permanecieron navegando durante más tiempo. Por esta razón, no se eliminaron en esta actividad. En una etapa posterior se podrá evaluar si conviene conservarlos, transformarlos o aplicar algún tratamiento, dependiendo del modelo que se utilice.

7. Visualizaciones

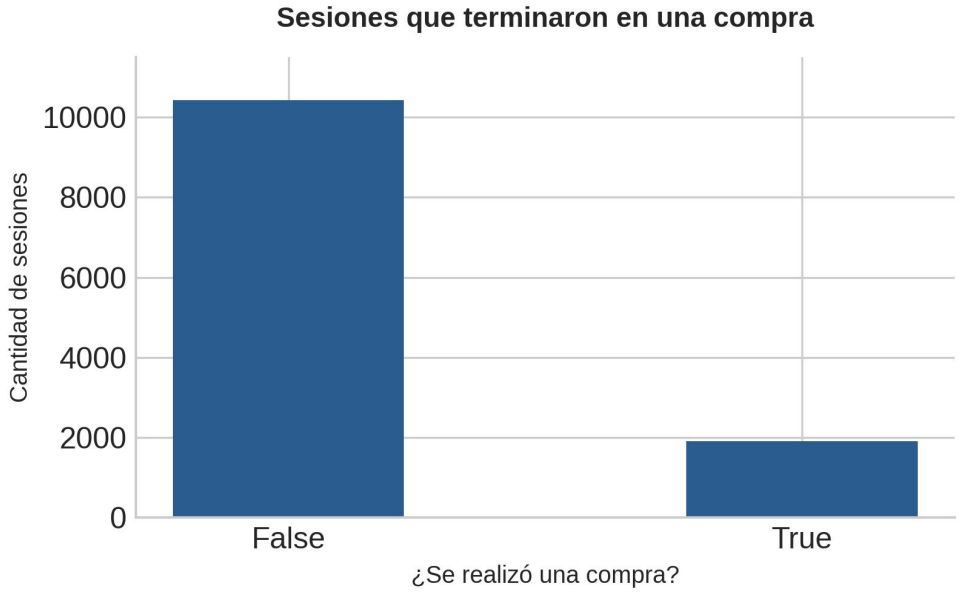
Las siguientes gráficas corresponden a las salidas visuales guardadas en el notebook. Se presentan como evidencia del análisis.

7.1 Sesiones por tipo de visitante



La mayor cantidad de sesiones corresponde a visitantes recurrentes; los visitantes nuevos son menos y la categoría Other es pequeña.

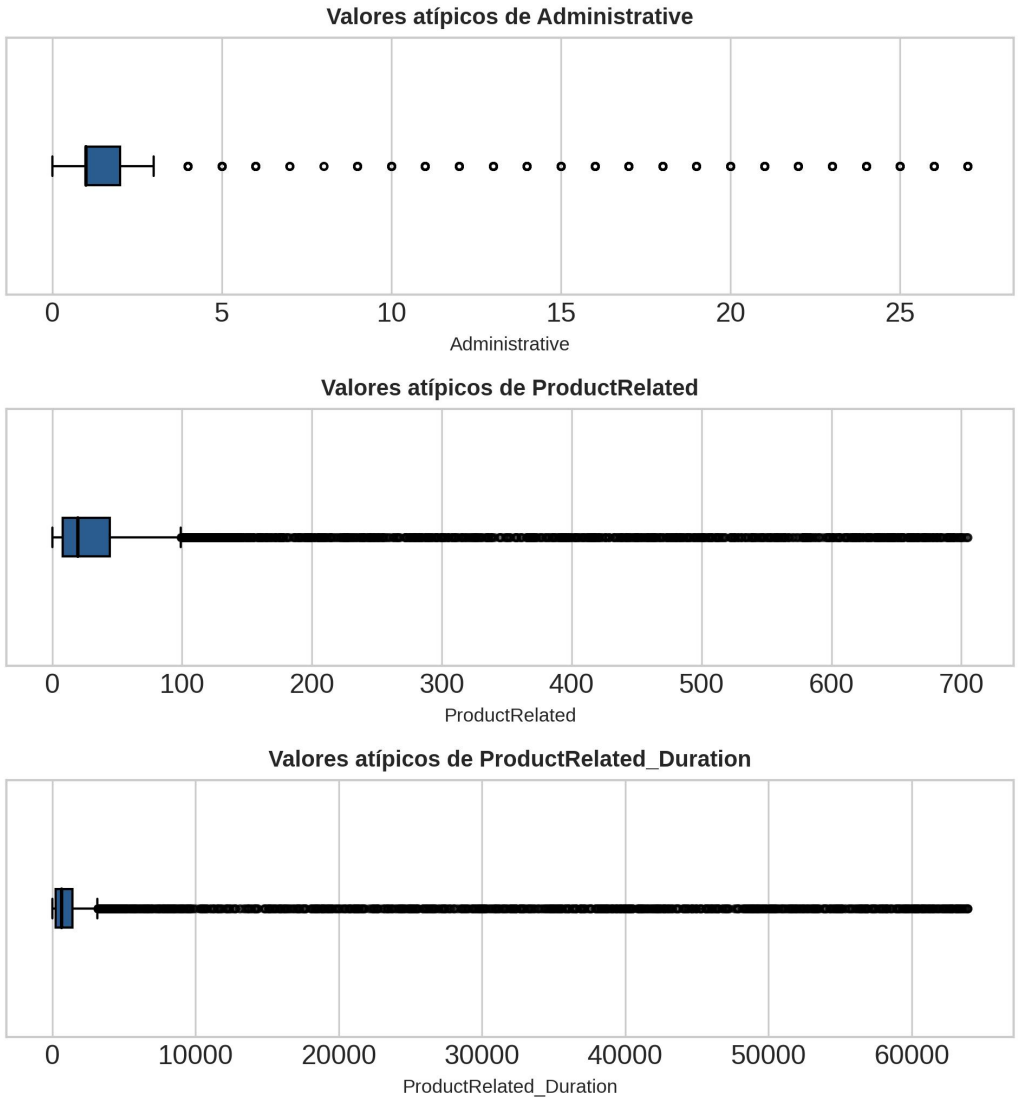
7.2 Sesiones que terminaron en una compra



Se observan más sesiones sin compra (False) que sesiones con compra (True).

7.3 Diagramas de caja de las variables seleccionadas

Los diagramas de caja permiten observar la dispersión y los valores que se encuentran alejados del rango central de cada variable. Se muestran los resultados de las tres variables analizadas.



Nota sobre el histograma

En el notebook, la celda titulada "Histograma: tiempo de navegación" contiene una gráfica de barras de Revenue en lugar de un histograma de ProductRelated_Duration. Por ello, no se presenta como histograma en este informe para evitar atribuirle una interpretación incorrecta. La interpretación del tiempo de navegación se apoya en las estadísticas y los diagramas de caja disponibles.

8. Propuesta de variables para modelos

Tipo de modelo	Variable(s) propuesta(s)	Objetivo
Regresión	ProductRelated_Duration	Estimar el tiempo que un usuario permanece navegando en páginas de productos.
Clasificación	Revenue	Predecir si una sesión termina o no en una compra (True/False).
Agrupamiento (clustering)	Administrative, ProductRelated, ProductRelated_Duration	Formar grupos de sesiones con comportamientos de navegación similares.

Estas propuestas permitirán estudiar el comportamiento de los compradores y buscar patrones que puedan ser útiles para comprender las visitas en el comercio electrónico.

9. Conclusión general

Durante esta actividad se realizó una exploración del conjunto de datos Online Shoppers Purchasing Intention Dataset, el cual contiene información sobre el comportamiento de los usuarios durante sus sesiones en una tienda en línea. El conjunto cuenta con 12,330 registros y 18 variables. La información está organizada en filas y columnas, por lo que se considera un conjunto de datos estructurado.

Al revisar la calidad de los datos, se encontró que ninguna variable tiene valores faltantes. Sin embargo, se identificaron 125 registros duplicados. También se revisaron algunas variables numéricas y no se encontraron valores negativos. Se observó una posible diferencia en el formato de los nombres de los meses, por ejemplo, June y Jul, que podría revisarse durante la limpieza de datos.

En el análisis estadístico se observó que los usuarios visitan en promedio 2.32 páginas administrativas y 31.73 páginas relacionadas con productos. También se encontró que el tiempo promedio en páginas de productos es de 1194.75 segundos. La diferencia entre las medias y medianas indica que existen sesiones con valores considerablemente mayores que los de la mayoría de los usuarios.

Mediante el método del rango intercuartílico se identificaron valores atípicos en las tres variables revisadas: 782 en Administrative, 1240 en ProductRelated y 1203 en ProductRelated_Duration. Estos valores no necesariamente representan errores, ya que podrían corresponder a usuarios que navegaron durante más tiempo o visitaron más páginas. Por esta razón, no se eliminaron durante esta actividad.

Las gráficas permitieron observar que la mayoría de las sesiones pertenecen a visitantes recurrentes y que una cantidad mayor de sesiones termina sin realizar una compra. También se observó que el tiempo de navegación en páginas de productos varía entre los usuarios.

Para futuros modelos se propone utilizar ProductRelated_Duration en un modelo de regresión, Revenue en uno de clasificación y las variables Administrative, ProductRelated y ProductRelated_Duration para realizar agrupamientos mediante clustering.

En general, considero que el conjunto de datos es adecuado para analizar el comportamiento de los compradores en el comercio electrónico. Antes de utilizarlo para entrenar modelos, sería conveniente revisar los registros duplicados, comprobar los formatos de las categorías y evaluar el tratamiento de los valores atípicos. En una siguiente etapa también se podrían preparar y transformar las variables según las necesidades de cada modelo.